

MILESTONE 5 · DONNÉES & CLASSIFICATION

Modèle de données et classification

Modèle conceptuel des données et grille de classification en quatre niveaux

Projet **PlantCare AI** — Big Data / IA · Groupe **MSI-5-26-BD** · Équipe : **Tina, Kaavya, Nathan, Thomas** · Client : Zineb Lamri · **Juillet 2026**


Ce document présente le modèle des données qui circulent dans le datalake et l'application, puis applique à chaque source et à chaque table la grille de classification en quatre niveaux imposée par le cahier des charges, avec la justification et la contrainte associées.

1. Modèle de données

Le cœur du modèle relie l'utilisateur à ses plantes et chaque plante à son espèce. Un **utilisateur** possède une ou plusieurs **plantes**, caractérisées par leur emplacement et la taille de leur pot ; chaque plante se rattache à une **espèce** du catalogue botanique, qui porte les caractéristiques d'entretien telles que le besoin de lumière, l'humidité et l'intervalle de température. Chaque plante accumule un **historique de soins** recensant les arrosages, rempotages et fertilisations, ainsi qu'une éventuelle référence de photographie. Les **mesures de capteurs** — humidité du sol, température et luminosité — sont associées à la plante et horodatées, tandis que les **observations météorologiques** sont rattachées à la ville de l'utilisateur.

Deux entités matérialisent les sorties de l'intelligence artificielle. L'**analyse d'image** conserve l'espèce prédite et le score de confiance produits par le modèle de vision, et la **recommandation** mémorise les verdicts d'arrosage du modèle maison comme les conseils générés par le modèle de langage. Ce schéma constitue le modèle conceptuel présenté ci-dessous ; il se décline ensuite en un modèle logique où les associations un-à-plusieurs deviennent des clés étrangères et où les données brutes du datalake alimentent, après nettoyage, les tables de service.

2. Modèle conceptuel des données



Modèle conceptuel des données de PlantCare AI (entités principales et cardinalités).

3. Grille de classification des données

Chaque source et chaque table sont classées selon les quatre niveaux définis par le cahier des charges. Cette classification conditionne directement la roadmap IA : une donnée sensible oriente vers un modèle interne ou auto-hébergé plutôt que vers une API externe non maîtrisée.

Source / table	Classe	Justification	Contrainte associée
Catalogue d'espèces (CSV / Trefle)	Publique	Données botaniques de référence, librement diffusables.	Aucune restriction particulière.
Observations météo (Open-Meteo)	Publique	Données environnementales ouvertes.	Aucune restriction particulière.
Images du dataset PlantNet-300K	Publique / Interne	Jeu public déjà filtré des visages et personnes.	Usage restreint au projet, citation de la source.
Mesures de capteurs simulés	Interne	Données techniques générées, sans caractère personnel.	Accès limité aux membres du projet.
Plantes de l'utilisateur (emplacement, pot)	Interne	Renseignent indirectement le domicile.	Accès restreint, non diffusé hors application.

Source / table	Classe	Justification	Contrainte associée
Historique de soins (habitudes)	Interne	Comportement pouvant devenir révélateur une fois agrégé.	Accès nominatif, pas de partage externe.
Profil utilisateur (email, ville)	Sensible	Donnée personnelle et de localisation au sens du RGPD.	Pseudonymisation, pas d'envoi brut à une API externe.
Photos téléversées par l'utilisateur	Sensible	Peuvent révéler l'intérieur du domicile et des métadonnées.	Traitement par modèle interne, hébergement privé, pas d'API hors UE sans base légale.
Analyses d'images (résultats)	Interne	Dérivées, sans donnée personnelle directe.	Accès restreint au projet.
Recommandations générées	Interne	Produits du système, pseudonymisés en amont.	Charge utile pseudonymisée avant tout appel externe.
Logs applicatifs et suivi des runs	Interne	Journaux techniques d'exploitation.	Rétention limitée, accès équipe.